



Robert Hendrich, Lukas Pilz und Leon Frey


Dresden, 21. Juli 2026

Gestaltungsansätze der Advanced Data Analytics

Group 3: Cycling Stage Prediction

Gliederung

1. Recap
2. Evaluationsstrategie
3. ML-Modelle
 - 3.1 EBM
 - 3.2 XGBoost
 - 3.3 TabPFN
 - 3.4 XGBoost Ranker
 - 3.5 Modellvergleich
4. Prediction-Tool






1. Recap

Robert Hendrich, Lukas Pilz und Leon Frey
Dresden, 21. Juli 2026

1. Recap

Zielstellung:

- Vorhersage von Etappenplatzierungen im Straßenradsport
- Einsatz interpretierbarer Machine-Learning-Modelle



1. Recap




Ausgangskonflikt

- Teaminterne Diskussion: *Regressor* vs. *Classifier*
- Impuls von Julian: Einsatz eines abgeänderten *Frank-und-Hall-Ansatzes*

Grundidee des Ansatzes

- Zerlegung des ordinalen Platzierungsproblems in drei binäre Zielkanäle (Top 5, Top 10, Top 20)
- Training separater binärer Klassifikatoren je Zielkanal
- Ausgabe je Fahrer: Wahrscheinlichkeit pro Kanal



1. Recap




Vorteile des Ansatzes

- Berücksichtigung der ordinalen Natur der Zielvariable
- Einheitliche Anwendbarkeit auf EBM, TabPFN und XGBoost

Einschränkung des Ansatzes

- Unabhängiges Training der drei Wahrscheinlichkeiten $P(\text{Top5})$, $P(\text{Top10})$, $P(\text{Top20})$
- Verletzung der Monotoniebeziehung
 $(P(\text{Top5}) \leq P(\text{Top10}) \leq P(\text{Top20}))$ in ca. 50% der Testfälle



1. Recap




- 1) **Data collection, integration, and cleaning** (e.g., filtering, harmonization, noise removal, removal of duplicates, missing values, feature scaling, etc.)
- 2) **Descriptive data analysis for data exploration & data understanding** (e.g., dataset properties, distribution, univariate, bivariate, multi-variate, correlations, imbalance, etc.)
- 3) **Development of an automated machine learning pipeline** (feature preparation, sampling/data splitting, model training, evaluation strategy, etc.)
- 4) **Implementation of different machine learning models**
 - **Simple models** (e.g., *linear models, decision tree*)
 - **Advanced flexible models** (e.g., *tree-based ensembles, deep neural networks, tabular foundation models*)
 - **Advanced interpretable models** (e.g., *generalized additive models*)
- 5) **Model evaluation, diagnosis, interpretation** (post-hoc explanations, interpretable model structure)




2. Evaluationsstrategie

Robert Hendrich, Lukas Pilz und Leon Frey
Dresden, 21. Juli 2026



2. Evaluationsstrategie





3. ML-Modelle

3.1 EBM Modell


Robert Hendrich, Lukas Pilz und Leon Frey
Dresden, 21. Juli 2026



3.1 EBM Modell

- Interpretierbares Glass-Box-Modell
- Additive Modellstruktur: einzelne Feature-Beiträge -> Basismodell
- Erweiterung zu GA^2M : ausgewählte Feature-Interaktionen
- Bei uns: 3 binäre Modelle für Top 5, Top 10 und Top 20- Score dient anschließend zur etappenweisen Sortierung

3.1 EBM Modell cont.







3.2 XGBoost

Robert Hendrich, Lukas Pilz und Leon Frey
Dresden, 21. Juli 2026


3.2 XGBoost



XGBoost Lernkurven




ROC-Kurven



Feature Importance

Feature Importance je XGBoost-Modell (Top 5 / Top 10 / Top 20)





3.3 TabPFN

Robert Hendrich, Lukas Pilz und Leon Frey
Dresden, 21. Juli 2026

3.3 TabPFN – Einführung & Setup

- Foundation Model für Tabellendaten
- Transformer, der Trainingsbeispiele werden als Kontext verarbeitet
→ In-Context-Learning
- Modellauswahl: 40 Konfigurationen auf Validierung 2023 (Top-10-Kanal, ROC-AUC)


3.3 TabPFN – Standard vs. Thinking

Metrik	Standard	Thinking
ROC-AUC	0,7805	0,7803
NDCG@5	40,84 %	41,85 %
NDCG@10	40,18 %	39,38 %
NDCG@20	43,30 %	42,85 %
MAP@10	0,1859	0,1785
Winner Hit@1	20,72 %	24,32 %
Winner Hit@10	57,66 %	52,25 %
Winner Hit@20	66,67 %	63,06 %
Laufzeit	≈ 112 s	≈ 360 s

- Spitzenprognose: Thinking besser
- Breite Rangliste: Standard besser
- Thinking: ca. 3-fache Laufzeit, Limit 20 Fits/Monat

3.3 TabPFN – Evaluation & Interpretation

- Finaler Test 2024/25
→ stärkstes Modell für die Spitzenprognose
- SHAP nur auf einigen Zeilen
→ voller Testsplit überschreitet das API-Limit
- Streuung über Etappen nötig, sonst etappenweite Features ohne Effekt
- Saisonform dominiert





3.4 XGBRanker


Robert Hendrich, Lukas Pilz und Leon Frey
Dresden, 21. Juli 2026

3.4 XGBRanker

- Learning-to-Rank-Variante von XGBoost: Rangfolge innerhalb der Etappe wird direkt zum Trainingsziel
- Pairwise-Verfahren (LambdaMART): Lerngradienten entstehen nur aus effective pairs
- Unterschied: mehrstufiges Relevanzziel 3/2/1/0 statt binärer Kanäle und NDCG@10 zur Modellauswahl
- Argmax überfittet: tiefes Modell fällt im Test hinter die Baseline zurück
- 1-SE-Regel: flaches Modell (depth 5, lr 0,03)
- Test 2024/25: beste Spearman-Korrelation, Laufzeit wenige Sekunden

3.4 XGBRanker – Interpretation & Fazit

- SHAP-Werte per TreeExplainer auf den Testdaten
- Saisonform dominiert, dazu BMI und Höhenmeter
- team_tier praktisch ohne Einfluss
→ Folge des pairwise-Ansatzes





3.5 Modellvergleich

Robert Hendrich, Lukas Pilz und Leon Frey
Dresden, 21. Juli 2026

3.5 Modellvergleich

Metrik	EBM GA ² M	XGBoost	TabPFN Standard	XGBRanker
ROC-AUC	0,7757	0,7836	0,7805	0,7757
NDCG@5	34,44 %	40,87%	40,84%	41,31%
NDCG@10	38,25 %	38,85%	40,18%	39,30%
NDCG@20	43,47 %	42,14%	43,30%	41,73%
MAP@10	0,1667	0,1672	0,1859	0,1748
Winner Hit@1	16,22 %	18,02%	20,72%	18,92%
Winner Hit@5	40,54 %	39,64%	41,44%	42,34%
Winner Hit@10	51,35 %	51,35%	57,66%	52,25%
Winner Hit@20	67,57 %	63,06%	66,67%	63,06%
Spearman Rho	0,3042	0,3046	0,3045	0,3125
Laufzeit für das Training [s]	2543	4,24	112	1,2



4. Prediction-Tool

Robert Hendrich, Lukas Pilz und Leon Frey
Dresden, 21. Juli 2026

Vielen Dank für Eure
Aufmerksamkeit!

